

Introdução ao KNN

Olá pessoal, sejam todos bem-vindos!

Nesta aula vocês irão conhecer o k-Nearest Neighbors (ou KNN), um dos modelos de aprendizado de máquina, que traduzido seu nome do inglês significa os “k”s vizinhos mais próximos. É um modelo muito intuitivo, pois se vale da ideia simples de classificar elementos ou executar a regressão de alguns elementos, a partir da distância entre eles. Imagine que você precisa desenvolver um sistema que precise calcular a semelhança entre elementos. Seu resultado é a partir da semelhança. Essa semelhança pode ser calculada a partir de uma distância. Nesse caso, o modelo de knn aparece como uma alternativa interessante, pois resolve facilmente esse problema, uma vez que as métricas de distância conseguem calcular bem a similaridade entre dois indivíduos. Interessante, não é?

Então como o KNN possui uma intuição simples, a matemática por trás dele também é fácil de compreender. Nós iremos entender como esta distância é calculada utilizando a técnica da distância euclidiana, em seguida, aprenderemos a implementar o KNN para classificação e para regressão, usando a biblioteca do Sklearn. Também teremos uma compreensão geral de como este modelo funciona, a partir da apresentação de exemplos da execução dele, e por fim aprenderemos a avaliá-lo seguindo a métrica de acurácia e alterando alguns parâmetros, como a quantidade de vizinhos pesquisada.

No decorrer desse curso você irá aprender a utilizar o KNN para efetuar classificação, regressão em cima de um conjunto de elementos. Mas antes você precisa compreender como calcular a distância euclidiana, que é uma das métricas de distância mais utilizadas para esse propósito.

Vamos lá?

A distância euclidiana é aprendida por muitos durante o ensino médio. E também aprendemos e conhecemos o teorema de Pitágoras aquele que diz que, a soma dos catetos ao quadrado é igual a hipotenusa ao quadrado de um triângulo retângulo. Esta fórmula utilizada no teorema de Pitágoras é exatamente igual à fórmula da distância euclidiana.

Para tornar tudo um pouco mais claro irei mostrar um exemplo entre dois números quaisquer. Se quisermos mensurar a distância entre dois números iremos tomar como exemplo, os números 2 e 5.

A distância entre os números 2 e 5 é a subtração entre eles, porém essa subtração tem que ser efetuada com um certo cuidado, pois a ordem na qual iremos subtrair não deve fazer diferença no resultado. Logo, se pegarmos primeiro o ponto 5 e subtrairmos o ponto 2 teremos a distância igual a 3, mas, no caso contrário, se utilizarmos primeiro o ponto 2 e formos subtrair o ponto 5, teremos uma distância negativa e distâncias negativas não são interessantes até porque não existem. Então, como poderíamos tentar de alguma maneira transformar essa distância que é negativa em uma distância positiva?

Podemos usar a célula do nosso Jupyter Notebook para efetuar esse cálculo e podemos examinar o que está ocorrendo.

No caso, se utilizarmos 2-5, como estou escrevendo na célula o resultado será: -3. E isso não é interessante porque não reflete uma distância. Mas usando 2-5, porém elevando essa subtração ao quadrado iremos utilizar a seguinte conta para elevar ao quadrado no Python: $(2-5)**2$ (2, primeiro elemento -5), que é o segundo elemento. Os dois asteriscos seguidos significam que vamos efetuar uma exponenciação e o 2, ou seja, $(2-5)**2$.

Ao executar esta célula, teremos o 9 positivo até porque qualquer número negativo elevado ao quadrado, irá se tornar positivo. Então, $2-5 = -3$ $(-3)^2 = (-3 \times -3) = 9$.

Só que o 9 ainda não é a nossa distância final. Estamos tentando utilizar a distância euclidiana e para completar a distância euclidiana iremos repetir a mesma linha anterior só que iremos tirar a raiz quadrada deste número anterior, que é feita da seguinte maneira: vamos reaproveitar a linha anterior mas iremos colocá-la entre parênteses e adicionar dois * e (0.5), ou seja, estamos pegando o resultado da linha anterior e iremos elevá-la a 0.5. Elevar por 0.5 é igual a elevar a 1/2. E elevar a 1/2, é tirar a sua raiz quadrada. Logo, com esta linha: $((2-5)**2)**(0.5)$, teremos a subtração dos dois elementos que queremos saber a distância, estamos elevando essa subtração ao quadrado e estamos tirando a raiz. Ou seja, no fim, estamos elevando ao quadrado para eliminar um valor negativo e tirando a raiz para voltar para

um número normal. Então, o resultado desta operação será igual a 3 uma vez que $2-5$ ou $5-2$ vão ter distância de 3.

Em termos de distância, a distância entre 5 e 2, não interessa a ordem, é 3. E utilizando essa fórmula de elevar ao quadrado a subtração e tirar a raiz, temos o valor positivo da distância. E, desta maneira, aprendemos a utilizar a distância entre dois pontos que possuem apenas uma coordenada.

Como poderíamos utilizar algo para duas coordenadas?

Vamos imaginar a situação em que temos uma fruta na qual temos a massa da fruta e a sua cor o índice de cor. Então, queremos efetuar a distância entre dois elementos que possuem duas dimensões, ou seja, possuem duas características diferentes.

Iremos efetuar a mesma técnica anterior para cada um dos atributos diferentes da fruta.

Vamos supor que uma das frutas possui a sua massa 5 e a cor é igual a 0.75.

Iremos escrever isso em Python como uma lista, e iremos armazenar em uma variável, por exemplo:

```
a=[5,0.75]
```

```
b=[2,0.50]
```

ou seja, estamos representando na variável "a" uma fruta que possui massa=5 e cor 0.75. E a outra fruta na variável "b" que seria de massa=2 e cor 0.50.

Com isto, como conseguimos mensurar a distância entre essas duas frutas?

A distância entre essas duas frutas é um cálculo bem parecido com o anterior onde iremos, para cada um dos atributos primeiramente para as massas e depois para as cores utilizar a distância entre dois pontos. Porém, considerando apenas cada um dos atributos separadamente. Como faremos isso?

Primeiro, iremos utilizar a mesma distância que vimos anteriormente que seria para separar dois pontos.

Temos o 5 e o 2, ou seja, $5-2$, que seria a massa da fruta a menos a massa da fruta b.

Iremos elevar ao quadrado para evitar possíveis números negativos.

Então, elevado ao quadrado: $(5-2)^2$. E teremos o resultado dessa distância elevado ao quadrado.

E iremos somá-lo com o próximo atributo, com a subtração ao quadrado do próximo atributo, que seria: $((5-2)^2 + (0.75 - 0.50)^2)$. Estamos separando as duas dimensões a dimensão da massa e a dimensão da cor e estamos subtraindo-as, a massa de uma menos a massa da outra eleva ao quadrado e soma esse resultado com a massa de uma, menos a massa da outra elevado ao quadrado. Assim, temos as distâncias entre as duas coordenadas elevadas ao quadrado. E, por fim, iremos elevar todo o resultado por 0.5.

Dessa forma, a raiz quadrada será efetuada pelas somas das diferenças ao quadrado. Dessa maneira, o resultado ao executar esta linha seria: $((5-2)^2 + (0.75 - 0.50)^2)^{0.5}$, ou seja, estamos pegando as duas subtrações ao quadrado somando-as e tirando a raiz. E o resultado será algo em torno de: 3,010398. Em tela, temos um resultado maior. Mas, como ficou a ideia da distância nessa situação? Nesta situação, a distância entre os dois pontos, sendo cada ponto composto por duas coordenadas, nós efetuamos a subtração de cada coordenada entre os pontos elevamos essa subtração ao quadrado e tiramos a raiz quadrada do geral. Então, esta fórmula da distância entre dois pontos pode ser replicada para quantas coordenadas forem necessárias. No caso de estarmos trabalhando com dados cada coordenada é uma coluna do nosso dado. Então, iríamos efetuar a distância entre cada um dos elementos de coluna a coluna elevar ao quadrado esses resultados somar todos e tirar a raiz quadrada destes elementos. Dessa maneira, nós temos a distância entre dois pontos que podem ter quantas dimensões forem necessárias e iremos ter apenas um resultado que seria a distância. Conseguimos calcular a distância entre dois elementos, sendo eles quaisquer tipos de dados que possuam quaisquer números de colunas e podemos mensurar a distância entre dois elementos. Estamos encerrando este vídeo tendo apresentado a distância euclidiana que será determinante para a utilização do nosso método KNN. No próximo vídeo, iremos apresentar a intuição do KNN para podermos implementá-lo em seguida.

Até lá!