

Selecionando features com árvores de decisão

Olá!

Neste vídeo, iremos aprender como selecionar os atributos ou selecionar um conjunto de atributos interessante para a classificação de alguns elementos, de algumas tarefas.

Então, para esta tarefa iremos utilizar a árvore de decisão e utilizaremos um conjunto de dados com mais categorias com mais atributos, mais colunas.

Para isso, iremos aplicar um conjunto de dados de detecção de câncer de mama.

Este conjunto é um pouquinho maior, ele possui mais colunas e a árvore de decisão ajuda a checar a importância de cada uma das colunas na classificação de um dado. Então, iremos utilizar o seguinte: `from sklearn.tree import DecisionTreeClassifier`, com "D" maiúsculo, "T" maiúsculo e "C" maiúsculo em cada uma das três palavras, mesmo que elas estejam juntas.

Na próxima linha, utilizaremos: `from sklearn.datasets import load_breast_cancer`, que é o "dataset" de câncer de mama.

Então, iremos importar esses dados e efetuar a seguinte linha, onde iremos utilizar: `dt = DecisionTreeClassifier()`, lembrando que aqui podemos utilizar uma poda dizer a profundidade máxima de uma árvore, mas, neste caso só queremos exemplificar esta capacidade da árvore de decisão de retornar as importâncias de uma feature.

Dessa maneira temos que a árvore de decisão foi implementada.

Iremos utilizar: `X,y = load_breast_cancer(return_X_y=True)`.

Assim, teremos carregado o conjunto de dados de câncer de mama.

Então, neste exemplo, não efetuarei a divisão de "train" e "test" porque o interesse é, apenas, mostrar essa capacidade da árvore de decisão.

Então, não é uma modelagem válida estamos, apenas, tentando notar o que acontece no modelo.

Então, utilizaremos: `dt.fit(X,y)`. Estamos passando o conjunto de dados e treinando a árvore.

Só para conseguirmos ter uma boa ideia usaremos, na próxima linha: `X.shape`. E efetuar a execução deste comando e nós teremos 569 dados 569 elementos no conjunto de dados e 30 colunas. 30 colunas, às vezes, é algo muito grande e gostaríamos de diminuir.

Alguns modelos não têm bons resultados ao serem confrontados com muitas colunas.

Então, podemos utilizar o conjunto de dados aplicar a árvore de decisão nele e verificar as importâncias das features que é o que iremos fazer agora: `dt.feature_importances_`.

Ao executar isso, teremos um conjunto de 30 elementos, em que cada um deles terá o resultado da importância de cada um dos atributos utilizados na construção desse modelo para o seu resultado.

Então, teremos vários atributos iguais a 0 ou seja, que tiveram zero importância na construção do modelo.

Então, podemos eliminar esses atributos sem importância e eliminar alguns dos atributos com importância baixa uma vez que eles não podem sequer auxiliar na execução do modelo.

O modelo pode até se beneficiar da ausência de alguns dos atributos.

Então, essas são as importâncias das features podemos eliminá-las recursivamente por exemplo: eliminar a feature com a menor importância e rodar a árvore novamente. E, aí sim, iremos executar isso recursivamente até possuir um conjunto bem menor de features.

Esta é uma possibilidade.

Por que executamos recursivamente, ao invés de retirar todos de uma vez?

Porque as features em si podem ter alguma correlação entre elas.

Então, retirar uma feature pode mexer na importância de outra.

Por isso, vamos retirando uma a uma, recursivamente até que possamos ter um resultado bom.

Em algum momento, uma feature tirada pode diminuir a precisão do modelo.

Então, gostaríamos de manter a precisão mais alta possível o "score" do modelo o mais alto possível com o menor conjunto de features possível.

Então, podemos ir eliminando as features menores, uma por vez e retreinando o modelo para estudar a sua evolução.

E, com isso, encerramos a aula de árvores de decisão.

Espero que tenham aprendido e entendido como a árvore funciona

Até a próxima aula!