

O exemplo do "ou-exclusivo"

Olá!

Neste vídeo, comentaremos um pouco sobre as características do "ou-exclusivo".

O "ou-exclusivo" é uma porta lógica, que existe na lógica matemática e ela é extremamente importante, tanto para a computação quanto para a língua portuguesa, por exemplo, que utiliza bastante o nosso "ou-exclusivo". ou a porta XOR, utilizada na lógica.

Então, qual é a ideia do "ou-exclusivo"?

Nós temos dois sinais de entrada uma entrada 1 e a entrada 2, por exemplo.

Nós temos o conhecimento da porta lógica "e" e da porta lógica "ou".

A porta lógica "e", ou "and" que utilizamos em processamentos de sinais lógicos funciona da seguinte maneira: se as duas entradas forem 0, a minha saída, o meu "e", será 0.

Se uma das entradas for 1, a minha saída será 0 porque significa que eu não tenho a primeira informação e a segunda informação.

Agora, se as duas entradas forem 1, se elas forem verdadeiras a minha saída também será verdadeira no caso do "e" da porta lógica "e".

Então, se queremos uma informação:

"Compre banana e maçã" essa informação só vai ser satisfeita se os dois produtos forem comprados: banana e maçã.

Se você comprar banana, mas não comprar maçã ou comprar maçã, mas não banana ou não comprar nenhuma das duas, o nosso "e" é falso.

Temos, também, a porta "ou", que varia do "e" em relação ao caso em que apenas uma das duas é comprada.

Por exemplo: se não comprarmos nem a banana nem a maçã então, o nosso "ou" foi inválido.

No caso, se comprar somente a banana, mas não comprar a maçã ou comprar somente a maçã, mas não a banana, o "ou" está válido porque foi pedido para comprar banana ou maçã.

E se comprar as duas, também, banana e maçã quando foi pedido para comprar banana ou maçã do ponto de vista da porta lógica, isso está correto.

No caso do "ou", se ambas informações de entrada forem verdadeiras o "ou" simples, ou a porta "or", é verdadeiro.

Porém, há o caso do "ou-exclusivo", que utilizamos na língua portuguesa no qual, quando pedimos para executar a compra de banana ou maçã você não deve comprar as duas.

Uma das duas, exclusivamente, será satisfeita.

Ou seja, não comprar nem banana nem maçã vai falsificar a frase e comprar banana e maçã também vai falsificar a frase.

Ela só vai estar verdadeira se você comprar banana, mas não maçã ou comprar apenas maçã, mas não comprar banana.

Se formos construir um gráfico, utilizando este "ou-exclusivo" onde, no eixo horizontal, nós teremos a primeira entrada da variável e no eixo vertical, teremos a outra entrada nós temos que a origem dessas nossas coordenadas seja igual a 0, por exemplo, ou seja, se as duas variáveis forem 0, teremos "Falso" o nosso "ou-exclusivo" é falso.

Se as duas variáveis forem 1, a nossa informação também é falsa.

Porém, se apenas uma delas for 1, então será verdadeira.

Ao construirmos um gráfico com essas informações temos que os nossos dados não vão ser linearmente separáveis que esses dados não podem ser separados com uma reta.

Modelos lineares, tais como a regressão logística não seriam capazes de criar um modelo de classificação que conseguisse separar bem o "ou-exclusivo".

Então, precisamos de um modelo um pouco mais complexo que não trabalhe apenas com uma reta.

Nós precisamos de um modelo não linear e a rede neural pode ser não linear.

No caso, não temos nenhuma reta capaz de separar esses dados.

Então, iremos fazer o seguinte: vamos criar dois neurônios cada neurônio desses recebendo os valores de cada uma das variáveis, ou seja, o primeiro neurônio irá receber o valor da variável um e o valor de entrada da variável dois e o neurônio dois também irá receber o valor da variável um e o valor de entrada da variável dois.

Ou seja, os dois neurônios estão recebendo os dois valores.

Relembrando do nosso perceptron, cada entrada irá ter um peso.

Então, a variável um vai ter um peso ao entrar no neurônio um e vai ter outro peso ao entrar no neurônio dois.

Enquanto que a variável dois irá ter um peso para o neurônio um ela irá ter outro peso para o neurônio dois.

Teremos quatro pesos na nossa situação.

E se formos tentar relembrar e fazer uma conexão com o nosso neurônio podemos perceber que o nosso neurônio tem uma característica interessante: ele é o somatório dos valores de entrada com pesos.

Se formos relembrar disso, a soma dos valores de entrada com pesos é bem parecido com a nossa equação da reta que utilizamos na regressão linear, ou mesmo na regressão logística.

Então, cada neurônio se comporta como uma reta.

Fica faltando só o termo independente ou o coeficiente angular da reta que, no caso, será um incremento ou decremento em cada neurônio que é o que chamamos de bias.

Ele pode ser igual a 0, ou um valor qualquer e aí, teremos exatamente esse valor igual a uma equação da reta.

Cada neurônio se comporta como uma reta, então com pesos diferentes, esses neurônios irão representar retas diferentes.

E, no nosso exemplo, podemos ter uma reta que separa a informação de entrada em que os dois valores de entrada são falsos e podemos ter outra reta que separa as duas entradas verdadeiras das demais entradas.

Assim, teremos duas retas no nosso sistema cada uma delas representada por cada neurônio e se formos reparar se temos uma reta que separa os dois valores negativos os dois valores falsos dos demais estamos separando o "ou" normal, o "ou" simples onde temos apenas um "Falso" que seria os dois valores de entrada negativos e todos os outros verdadeiros, conseguimos separar desse modo.

Enquanto que a outra reta, que separa apenas os dois verdadeiros dos demais pode ser o nosso "e", a nossa rota lógica "and" "e" porque ela está separando só os dois verdadeiros dos demais.

Podemos dizer que o que está acima, de um lado dessa reta é verdadeiro e o que está do outro lado é falso.

Então, nós temos duas retas uma delas separando o "e", e outra delas separando o "ou" e podemos utilizar uma segunda camada de neurônios com apenas um neurônio Disponível que irá pegar o resultado dessas duas primeiras retas.

Assim, na segunda camada, receberemos os valores das primeiras retas como entrada, aplicando um peso a cada uma delas e construiremos uma nova reta, que terá como significado como semântica, o seguinte: caso os valores estejam abaixo das duas retas, ele é falso.

Caso esteja acima das duas retas, ele também é falso.

E se estiver entre as duas retas, será verdadeiro. Dessa maneira, temos o "ou-exclusivo" sendo exemplificado e mostrado porque uma das retas representa o "ou" ela vai negar apenas o caso dos dois negativos de entrada. E outra reta irá separar o caso onde temos os dois valores de entrada como positivos, que é o "e" e vai torná-los verdadeiros, e o restante falsos.

Se tivermos a situação em que os valores estão entre uma reta e outra teremos exatamente a situação em que um dos valores é falso e o outro é verdadeiro, que é o caso em que o "ou-exclusivo" é verdadeiro.

Nos demais casos, nosso "ou-exclusivo" é falso.

Então, o que acontece, na realidade é como se estivéssemos criando uma nova reta a partir de uma projeção dos nossos dados.

Ou seja, o nosso neurônio continua sendo uma reta, mas ele pega informações anteriores e trabalha em cima delas de outras retas.

Assim, é como se combinássemos retas, e quanto mais retas utilizamos melhor será a maneira como o sistema estará separando nossos dados.

Quanto mais complexo, mais neurônios que iremos precisar em cada camada complexo em relação ao padrão.

E enquanto precisamos de combinações entre as retas anteriores nós podemos utilizar mais neurônios na próxima camada e assim por diante.

A cada camada teremos sempre uma especialização da camada anterior.

Temos as retas anteriores e estamos trabalhando em cima delas e construindo algo mais complexo.

Então, as redes neurais funcionam dessa maneira: nós vamos construindo retas a cada neurônio e elas vão se especializando a cada camada para caracterizarem e encontrarem padrões cada vez mais complexos nos neurônios.

Com isso, encerramos este vídeo.

No próximo vídeo iremos começar a parte de implementação das redes neurais.

Iremos implementá-las de modo a utilizar o Scikit-learn para essas redes.

Até lá!