

O neurônio artificial

Olá!

Neste vídeo, iremos continuar a discussão sobre as redes neurais tentando entender um pouco como funciona um neurônio artificial o primeiro modelo de McCulloch-Pitts que é um modelo bem antigo, de 1943, mas, até hoje, ele ainda é utilizado como base para a rede neural por ser simplista, refletindo, de fato a computação que ocorre no neurônio humano no neurônio natural, além de eficaz.

Ele funciona muito bem, e ele tem algumas analogias com alguns modelos que trabalhamos em outras aulas.

Então, em relação ao neurônio artificial é importante compreender o seu funcionamento para que entendamos como a rede neural funciona como ela se comporta.

Então, o neurônio artificial vai ter a seguinte característica: podemos ter um conjunto de variáveis de entrada onde cada uma dessas variáveis irá levar uma informação.

Cada variável tem uma informação diferente.

É como se cada uma dessas variáveis fosse um impulso externo que podemos, também, traduzir como os nossos dados de entrada ou esta variável pode, também, ser o resultado da computação de um neurônio anterior.

Mas o nosso neurônio está sendo preparado dessa maneira: uma variável de entrada para cada sinal, ou seja, imaginando uma função cada variável dessa seria o parâmetro de entrada da função.

E dentro desse neurônio, a informação de entrada é processada, ou seja, alguma computação é feita e nós temos a saída desse neurônio que vai ser, por exemplo, 0 ou 1 nesse modelo mais simples de McCulloch-Pitts.

Então, nós temos várias entradas, que são parâmetros de uma função assim imaginamos a execução dessa função, e uma saída que, no caso desse primeiro modelo criado, era de 0 ou 1 e as entradas também eram de 0 ou 1.

Estamos combinando, de algum modo, a informação de entrada para produzir uma saída, ou seja, neurônio ativado ou desativado.

Tornando o modelo de McCulloch-Pitts uma equação matemática nós iremos ter um somatório dos valores de entrada dado que este somatório seja maior do que um limiar neste limiar, estamos utilizando 0, por exemplo.

Então, se o somatório dos valores de entrada é maior que 0 o nosso neurônio vai ser ativado, ou seja, o retorno será 1. Caso contrário, se for menor que 0, o nosso retorno será 0.

Ou seja, o nosso neurônio é ativado ou desativado de acordo com o valor de entrada. Então, se formos observar, o nosso neurônio a base da rede neural a informação atômica, o que a gente tem de mais simples ele possui uma característica, uma computação bem simples ele vai, apenas, efetuar um somatório dos dados de entrada e dependendo desse valor, retorna se esse neurônio foi ativado ou não.

Existem alguns pontos interessantes nesta teoria que evoluiu um pouco, utilizando a mesma base o neurônio de McCulloch-Pitts, porém, quando fomos utilizar a rede neural foi criado o conceito de perceptron.

O perceptron é bem parecido com a ideia anterior, ou seja, um somatório das entradas, porém, existe, agora, um peso que multiplica cada uma das entradas. Ou seja, para cada uma das variáveis de entrada nós temos, também, um peso associado a elas que é independente das demais.

Supondo que temos duas variáveis uma variável x_0 e uma variável x_1 .

Essa variável x_0 vai ter um peso w_0 e a variável x_1 vai ter um peso w_1 .

Então, iremos computar sobre esses pesos, ou seja, a nossa somatória que antes era a soma da variável x_0 mais a soma da variável x_1 agora, é o peso w_0 vezes o x_0 mais o w_1 , o peso 1 multiplicado pela variável x_1 .

Ou seja, cada peso irá multiplicar a sua variável correspondente e teremos a soma desses produtos.

Dessa maneira, estamos dando uma diferenciada nas informações que estão chegando no nosso neurônio.

O perceptron tem essa característica de ter o peso dessa forma, podemos diferenciar a entrada tornar um neurônio mais sensível a uma entrada e menos sensível a outra. E, assim, podemos ter uma diferenciação uma complexidade maior na informação que está chegando nesse neurônio e como essa informação irá sair.

Além disso, na rede neural, nós temos uma diferenciação que é o que chamamos de função de ativação.

A função de ativação é o seguinte: uma vez que essa soma é calculada somam-se os produtos de cada variável pelo seu peso, essa soma final passará por uma função de ativação que seria, basicamente, uma função que transforma o valor.

Um exemplo de função de ativação é a função que eu comentei há pouco.

Se o somatório for maior que 0, por exemplo o resultado que sairá desse neurônio, independente de quanto foi a soma será igual a 1.

Caso ele seja menor que 0, vai ser 0 não interessa, tampouco, quão pequeno ele é.

O somatório, obviamente, pode dar menor que 0 se tivermos, por exemplo, pesos negativos para as variáveis.

Então, a multiplicação seria negativa e teríamos uma subtração.

Essa função é bem simplista, dá como retorno 0 ou 1, por exemplo, mas temos outros tipos de funções, como a função de ativação linear que entrega exatamente o valor do somatório uma vez que foi executado o somatório das minhas entradas multiplicando as variáveis de entrada pelos pesos podemos entregar exatamente o valor do somatório sem fazer nenhuma modificação.

Esta é a função linear.

Temos, também, a função conhecida como "ReLU", Rectified Linear Unit que apenas retifica os valores menores que 0, ou seja, se o somatório der menor que 0 a minha

função do neurônio irá retornar igual a 0. Caso contrário, se for maior que 0, ela retorna o valor correspondente.

Esta função é bastante usada ao aplicar redes neurais a imagens reconhecimento de imagens reconhecimento de padrões em imagens e sons.

Existem algumas funções, cada uma delas tem sua utilidade seu propósito.

Nesta aula, iremos comentar poucas delas, mas existem várias.

Esta aula é introdutória nesta área de redes neurais e nosso modelo será o que chamamos de Multilayer Perceptron ou o perceptron de multicamadas que seria exatamente os neurônios conectados onde temos as variáveis de entrada que serão as entradas de cada uma das variáveis.

Imagine um conjunto de dados: cada elemento da coluna dos dados irá para um neurônio de entrada, que será uma variável. E aí, temos que a primeira camada dos neurônios irá receber exatamente os valores de fora, os que estão entrando no modelo e as camadas seguintes irão receber como entrada as suas variáveis onde serão executadas as suas computações serão as saídas das camadas anteriores de neurônios.

Dessa maneira, nós temos exatamente a ideia da especialização do dado.

A nossa informação vai ser passada nas camadas de neurônios e irá se especializando.

No próximo vídeo, irei mostrar um exemplo sobre como esta informação é propagada e o poder que isso dá para uma rede neural essa informação ser passada por neurônios tendo uma computação em cada um desses neurônios.

No próximo vídeo, falaremos sobre um exemplo de computação em redes neurais.

Até lá!